

**ΠΡΟΧΩΡΗΜΕΝΑ ΘΕΜΑΤΑ
ΤΕΧΝΟΛΟΓΙΑΣ ΚΑΙ ΕΦΑΡΜΟΓΩΝ
ΒΑΣΕΩΝ ΔΕΔΟΜΕΝΩΝ**

**ΠΡΟΓΡΑΜΜΑΤΙΣΤΙΚΗ ΕΡΓΑΣΙΑ ΓΙΑ
ΤΟ ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025-2026**

ΟΜΑΔΑ

ΔΙΟΝΥΣΙΟΣ - ΧΡΗΣΤΟΣ ΜΥΛΩΝΑΣ, ΑΜ 4443

ΝΑΤΑΛΙΑ ΜΙΧΟΥ, ΑΜ 4922

ΣΠΥΡΙΔΟΥΛΑ ΤΣΑΦΩΝΗ, ΑΜ 5373

ΤΕΛΙΚΗ ΑΝΑΦΟΡΑ

ΜΑΪΟΣ 2026

Περιεχόμενα

Ιστορικό εκδόσεων	2
1 Βάση Δεδομένων	3
1.1 Σχεσιακό Σχήμα σε Λογικό Επίπεδο	3
1.2 Σχεσιακό Σχήμα σε Φυσικό Επίπεδο	6
1.2.1 Ρύθμιση παραμέτρων του DBMS	6
1.2.2 Ρύθμιση φυσικού σχήματος	7
1.2.3 Ρύθμιση ασφαλείας	8
2 Αρχιτεκτονική Λογισμικού	8
2.1 Αρχιτεκτονική και Δομή ETL	8
2.2 Διαγράμματα Πακέτων / Υποσυστημάτων Κεντρικής Εφαρ- μογής	16
2.3 Διαγράμματα Κλάσεων Κεντρικής Εφαρμογής	16
3 Υποδείγματα Ερωτήσεων και Απαντήσεων	17
3.1 Homepage	17
3.2 Venue Profile	18
3.3 Author Profile	19
3.4 Year Profile	20
3.5 Line Charts	21
3.6 Bar Charts	23
3.7 Scatter Plots	24
4 Λοιπά Σχόλια	26
4.1 Επιλογές Σχεδιασμού και Trade-offs	26
4.2 Επιλογές Setup	26
4.3 Επιλογές Εφαρμογής Bibinator	26
4.4 Γνωστοί Περιορισμοί	26
4.5 Εκτέλεση Εφαρμογής	27


Ιστορικό εκδόσεων

Ημερομηνία	Έκδοση	Περιγραφή	Συγγραφέας
2026/03/28	1.0	Δημιουργία σχήματος βάσης	Ομάδα
2026/04/07	2.0	Αρχή ETL pipeline	Ομάδα
2026/04/15	2.1	Ολοκλήρωση ETL pipeline	Ομάδα
2026/04/16	3.0	Δημιουργία σκελετού εφαρμογής	Ομάδα
2026/04/28	4.0	Ολοκλήρωση εφαρμογής, SQL Queries	Ομάδα
2026/05/02	5.0	Tests	Ομάδα
2026/05/21	5.1	Τελική υποβολή	Ομάδα

1 Βάση Δεδομένων

Η βάση δεδομένων της εργασίας μας αποθηκεύει βιβλιογραφικά δεδομένα (άρθρα, συγγραφείς, κατατάξεις συνεδρίων και επιστημονικών περιοδικών) που προέρχονται από τα DBLP, iCORE 2026 και Kaggle datasets. Χρησιμοποιείται **MariaDB (HeidiSQL)** ως DBMS.

1.1 Σχεσιακό Σχήμα σε Λογικό Επίπεδο



EER Diagram του σχήματος bibinatorDB (MySQL Workbench)

Το σχήμα της βάσης δεδομένων μας αποτελείται από εννέα (9) πίνακες οργανωμένους σε τρία επίπεδα:

Lookup tables

Αποθηκεύουν τιμές αναφοράς που χρησιμοποιούνται ως foreign keys: FOR_LOOKUP (κωδικοί Fields of Research), BEST_SUBJECT_AREA_LOOKUP (θεματικές κατηγορίες) και AUTHOR_LOOKUP (ονόματα συγγραφέων).

Fact tables

Κύριες οντότητες: ARTICLES (όλα τα άρθρα), CONF_RANKING (κατατάξεις iCORE),

MAG_RANKING (κατατάξεις Kaggle).

Junction / Info tables

Συνδέουν άρθρα με venues και συγγραφείς: CONF_ARTICLE_INFO, MAG_ARTICLE_INFO, ARTICLE_AUTHORS.

DDL τελικών πινάκων

```
DROP TABLE IF EXISTS `article_authors`;
CREATE TABLE `article_authors` (
  `article_id` int(11) NOT NULL,
  `author_id` int(11) NOT NULL,
  PRIMARY KEY (`article_id`,`author_id`),
  KEY `fk_aa_author` (`author_id`),
  CONSTRAINT `fk_aa_article` FOREIGN KEY (`article_id`) REFERENCES `
    articles` (`article_id`),
  CONSTRAINT `fk_aa_author` FOREIGN KEY (`author_id`) REFERENCES `
    author_lookup` (`author_id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `articles`;
CREATE TABLE `articles` (
  `article_id` int(11) NOT NULL,
  `title` varchar(255) DEFAULT NULL,
  PRIMARY KEY (`article_id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `author_lookup`;
CREATE TABLE `author_lookup` (
  `author_id` int(11) NOT NULL,
  `author_name` varchar(255) DEFAULT NULL,
  PRIMARY KEY (`author_id`),
  KEY `idx_au_author_name` (`author_name`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `best_subject_area_lookup`;
CREATE TABLE `best_subject_area_lookup` (
  `best_subject_area_id` int(11) NOT NULL,
  `best_subject_area_name` varchar(255) DEFAULT NULL,
  PRIMARY KEY (`best_subject_area_id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `conf_article_info`;
CREATE TABLE `conf_article_info` (
  `article_id` int(11) NOT NULL,
  `conf_id` int(11) DEFAULT NULL,
  `year` int(11) DEFAULT NULL,
  PRIMARY KEY (`article_id`),
  KEY `fk_cai_conf` (`conf_id`),
  CONSTRAINT `fk_cai_article` FOREIGN KEY (`article_id`) REFERENCES `
    articles` (`article_id`),
```

```

    CONSTRAINT `fk_cai_conf` FOREIGN KEY (`conf_id`) REFERENCES `conf_ranking`
      (`conf_id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `conf_ranking`;
CREATE TABLE `conf_ranking` (
  `conf_id` int(11) NOT NULL,
  `title` varchar(255) DEFAULT NULL,
  `acronym` varchar(255) DEFAULT NULL,
  `conf_rank` varchar(255) DEFAULT NULL,
  `primary_for` int(11) DEFAULT NULL,
  PRIMARY KEY (`conf_id`),
  KEY `fk_conf_ranking_for` (`primary_for`),
  CONSTRAINT `fk_conf_ranking_for` FOREIGN KEY (`primary_for`) REFERENCES `
    for_lookup` (`for_code`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `for_lookup`;
CREATE TABLE `for_lookup` (
  `for_code` int(11) NOT NULL,
  `for_name` varchar(255) DEFAULT NULL,
  PRIMARY KEY (`for_code`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `mag_article_info`;
CREATE TABLE `mag_article_info` (
  `article_id` int(11) NOT NULL,
  `mag_id` int(11) DEFAULT NULL,
  `year` int(11) DEFAULT NULL,
  PRIMARY KEY (`article_id`),
  KEY `fk_mai_mag` (`mag_id`),
  CONSTRAINT `fk_mai_article` FOREIGN KEY (`article_id`) REFERENCES `
    articles` (`article_id`),
  CONSTRAINT `fk_mai_mag` FOREIGN KEY (`mag_id`) REFERENCES `mag_ranking`
    (`mag_id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;

DROP TABLE IF EXISTS `mag_ranking`;
CREATE TABLE `mag_ranking` (
  `mag_id` int(11) NOT NULL,
  `title` varchar(255) DEFAULT NULL,
  `mag_rank` decimal(10,4) DEFAULT NULL,
  `best_quartile` varchar(2) DEFAULT NULL,
  `total_docs` int(11) DEFAULT NULL,
  `total_docs_3y` int(11) DEFAULT NULL,
  `total_refs` int(11) DEFAULT NULL,
  `total_cites_3y` int(11) DEFAULT NULL,
  `citable_docs_3y` int(11) DEFAULT NULL,
  `cites_per_doc_2y` decimal(10,4) DEFAULT NULL,
  `refs_per_doc` decimal(10,4) DEFAULT NULL,
  `best_subject_area_id` int(11) DEFAULT NULL,

```

```
`publisher` varchar(255) DEFAULT NULL,
PRIMARY KEY (`mag_id`),
KEY `fk_mag_ranking_bsa` (`best_subject_area_id`),
CONSTRAINT `fk_mag_ranking_bsa` FOREIGN KEY (`best_subject_area_id`)
REFERENCES `best_subject_area_lookup` (`best_subject_area_id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COLLATE=utf8mb4_unicode_ci;
```

Τελικό σχήμα βάσης δεδομένων – bibinatorddb

Σχεδιαστικές επιλογές και trade-offs

Διαχωρισμός άρθρων συνεδρίων / περιοδικών: Τα CONF_ARTICLE_INFO και MAG_ARTICLE_INFO αποθηκεύουν 1 εγγραφή ανά άρθρο (article_id ως PK), αποφεύγοντας πολλαπλασιασμό εγγραφών στους fact πίνακες. Ο τύπος venue βρίσκεται από το ποιος info table περιέχει το άρθρο. Η εγγραφή ότι κάθε άρθρο ανήκει σε ακριβώς έναν τύπο υπάρχει στη λογική του ETL.

ARTICLE_AUTHORS ως bridge table (M:N): Το composite PK (article_id, author_id) εξασφαλίζει μοναδικότητα. Κρατά τους info tables καθαρούς αλλά απαιτεί επιπλέον JOIN για κάθε ερώτημα με συγγραφείς.

Συνθετικά PKs στους lookup tables: Τα string primary keys απορρίφθηκαν υπέρ INTEGER surrogates για αποδοτικά JOINS.

Έτος στους info tables αντί στον ARTICLES: Το έτος είναι ιδιότητα του γεγονότος δημοσίευσης, όχι του άρθρου.

Αριθμητικοί τύποι στο MAG_RANKING: Τα μετρικά πεδία αποθηκεύονται ως INT/DECIMAL. Τιμές εκτός Q1–Q4 στο best_quartile αποθηκεύονται ως NULL.

Placeholder no_author: Άρθρα χωρίς συγγραφέα στο DBLP λαμβάνουν τον placeholder no_author ώστε να παραμένουν προσβάσιμα.

1.2 Σχεσιακό Σχήμα σε Φυσικό Επίπεδο

1.2.1 Ρύθμιση παραμέτρων του DBMS

Παράμετρος	Τιμή	Αιτιολογία
local_infile	ON	Απαραίτητο για LOAD DATA LOCAL INFILE
foreign_key_checks	0 κατά φόρτωση, 1 μετά	Ταχύτερη φόρτωση μεγάλων CSV
Storage engine	InnoDB	FK, transactions, row-level locking
Character set	utf8mb4_unicode_ci	Για case insensitivity

Η σύνδεση ρυθμίζεται μέσω config.ini:

```
[database]
host      = 127.0.0.1
```

```

port      = 3306
user      = root
password  = root
name      = bibinatorDB

[setup]
mode = original_files
; mode = backup
; mode = validate
run_tests      = true
drop_staging_tables = true
export_final_tables = false
create_backup   = true

[app]
port = 8501
mode = run
;mode = test_queries

```

config.ini

1.2.2 Ρύθμιση φυσικού σχήματος

Ευρετήρια (Indexes) Η MySQL δημιουργεί αυτόματα B-Tree indexes στα Primary Keys και Foreign Keys. Επιπλέον, το ETL pipeline δημιουργεί indexes κατά τη διαδικασία δημιουργίας των intermediate tables. Επισημαίνουμε ότι η χρήση της εντολής CREATE INDEX IF NOT EXISTS είναι δυνατή μόνο για MariaDB και όχι MySQL.

```

CREATE INDEX IF NOT EXISTS idx_iaa_article_id ON
  intermediate_article_author (article_id);
CREATE INDEX IF NOT EXISTS idx_iaa_author_name ON
  intermediate_article_author (author_name);
CREATE INDEX IF NOT EXISTS idx_au_author_name ON AUTHOR_LOOKUP (
  author_name);
CREATE INDEX IF NOT EXISTS idx_sca_id ON starting_conf_articles (
  id);
CREATE INDEX IF NOT EXISTS idx_sma_id ON starting_mag_articles (id);
CREATE INDEX IF NOT EXISTS idx_ica_article_id ON intermediate_conf_articles
  (article_id);
CREATE INDEX IF NOT EXISTS idx_ima_article_id ON intermediate_mag_articles
  (article_id);

```

Τα πεδία CONF_RANKING.title, .acronym και MAG_RANKING.title χρησιμοποιούνται με LIKE '%term%' — αυτός ο τύπος δεν επωφελείται από B-Tree index. Επειδή οι ranking πίνακες είναι μικροί, το full scan εκτελείται σε αμελητέο χρόνο.

Προσωρινοί πίνακες κατά ETL Κατά τη φόρτωση χρησιμοποιούνται temporary tables (tmp_conf_categories, tmp_mag_categories, tmp_conf_id_map, tmp_mag_id_map) για να ενσωματωθούν τα αποτελέσματα του fuzzy matching.

1.2.3 Ρύθμιση ασφαλείας

Η εφαρμογή λειτουργεί σε τοπικό περιβάλλον ανάπτυξης με χρήστη root. Για παραγωγικό περιβάλλον θα ορίζονταν:

Ρόλος	Δικαιώματα	Χρήση
app_reader	SELECT σε όλους τους πίνακες	Streamlit frontend
etl_loader	INSERT, UPDATE, DROP, CREATE	ETL pipeline

2 Αρχιτεκτονική Λογισμικού

2.1 Αρχιτεκτονική και Δομή ETL


Η ETL διαδικασία υλοποιείται σε **Python 3.14** και υποστηρίζει δύο εναλλακτικούς τρόπους φόρτωσης μέσω config.ini:

Mode	Script	Περιγραφή
original_files	full_pipeline.py	Πλήρης pipeline από ακατέργαστα CSV/XLSX
backup	backup_pipeline.py	Αποκατάσταση από .sql.gz backup

Πηγές δεδομένων

Αρχείο	Μέγεθος	Πηγή	Περιεχόμενο
input_inproceedings.csv	401 MB	DBLP	Άρθρα συνεδρίων
input_article.csv	331 MB	DBLP	Άρθρα περιοδικών
iCore26_KilledColumnsForLoading.csv	120 KB	iCORE 2026	Κατατάξεις συνεδρίων
journal_ranking_data_raw.csv	5.4 MB	Kaggle	Κατατάξεις περιοδικών
icoreCategories.xlsx	14 KB	iCORE	Κωδικοί FoR
bestSubjectArea.csv	1KB	Kaggle	Κατηγορίες θεματικών

Περιγραφή ETL Pipeline (Mode: original_files)



ETL Pipeline Diagram

Η φόρτωση γίνεται σε έξι στάδια με καθορισμένη σειρά για την τήρηση των FK εξαρτήσεων:

Στάδιο 1 — Starting tables: Τα αρχικά αρχεία φορτώνονται αυτούσια σε `starting tables` χωρίς μετασχηματισμό (`LOAD DATA LOCAL INFILE`). Όλες οι στήλες ως `VARCHAR` για να μην αποτύχει η φόρτωση. Για κάθε αρχείο ορίζεται ο κατάλληλος χαρακτήρας διαχωρισμού και `OPTIONALLY ENCLOSED BY ''`.

starting_conf_articles	
123 id	int(11)
A:Z author	varchar(255)
A:Z booktitle	varchar(255)
A:Z cdrom	varchar(255)
A:Z cite	varchar(255)
A:Z cite_label	varchar(255)
A:Z crossref	varchar(255)
A:Z editor	varchar(255)
A:Z ee	varchar(255)
A:Z i	varchar(255)
A:Z articleKey	varchar(255)
A:Z mdate	varchar(255)
A:Z month	varchar(255)
A:Z note	varchar(255)
A:Z number	varchar(255)
A:Z pages	varchar(255)
A:Z pubtype	varchar(255)
A:Z sub	varchar(255)
A:Z sup	varchar(255)
A:Z title	varchar(255)
A:Z titleBibtex	varchar(255)
A:Z tt	varchar(255)
A:Z url	varchar(255)
123 year	int(11)

starting_mag_articles	
123 id	int(11)
A:Z author	varchar(255)
A:Z booktitle	varchar(255)
A:Z cdrom	varchar(255)
A:Z cite	varchar(255)
A:Z citeLabel	varchar(255)
A:Z crossref	varchar(255)
A:Z editor	varchar(255)
A:Z ee	varchar(255)
A:Z i	varchar(255)
A:Z journal	varchar(255)
A:Z articleKey	varchar(255)
A:Z mdate	varchar(255)
A:Z month	varchar(255)
A:Z note	varchar(255)
A:Z number	varchar(255)
A:Z pages	varchar(255)
A:Z publisher	varchar(255)
A:Z pubtype	varchar(255)
A:Z rating	varchar(255)
A:Z reviewid	varchar(255)
A:Z sub	varchar(255)
A:Z sup	varchar(255)
A:Z title	varchar(255)
A:Z titleBibtex	varchar(255)
A:Z tt	varchar(255)
A:Z url	varchar(255)
A:Z volume	varchar(255)
123 year	int(11)


starting_mag_ranking	
123 mag_rank	int(11)
A:Z Title	varchar(255)
A:Z OA	varchar(255)
A:Z Country	varchar(255)
123 SJR_index	decimal(10,4)
A:Z CiteScore	varchar(255)
A:Z H_index	varchar(255)
A:Z Best_Quartile	varchar(255)
A:Z Best_Categories	varchar(255)
A:Z Best_Subject_Area	varchar(255)
A:Z Best_Subject_Rank	varchar(255)
123 Total_Docs	int(11)
123 Total_Docs_three_y	int(11)
123 Total_Refs	int(11)
123 Total_Cites_three_y	int(11)
123 Citable_Docs_three_y	int(11)
123 Cites_or_Doc_two_y	decimal(10,4)
123 Refs_or_Doc	decimal(10,4)
A:Z Publisher	varchar(255)
A:Z Core_Collection	varchar(255)
A:Z Coverage	varchar(255)
A:Z Active	varchar(255)
A:Z In_Press	varchar(255)
A:Z ISO_Language_Code	varchar(255)
A:Z ASJC_Codes	varchar(255)
A:Z Life_Sciences	varchar(255)
A:Z Social_Sciences	varchar(255)
A:Z Physical_Sciences	varchar(255)
A:Z Health_Sciences	varchar(255)
A:Z General	varchar(255)
A:Z Agricultural_and_Biological_Sciences	varchar(255)
A:Z Arts_and_Humanities	varchar(255)
A:Z Biochemistry_Genetics_and_Molecular_Biology	varchar(255)

starting_conf_ranking	
123 id	int(11)
A:Z title	varchar(255)
A:Z acronym	varchar(255)
A:Z source	varchar(255)
A:Z conf_rank	varchar(255)
A:Z dblp	varchar(255)
123 primaryFoR	int(11)

Starting tables — screenshot από MySQL Workbench (στο starting_mag_ranking κόπηκαν γραμμές λόγω μήκους)

Στάδιο 2 — Επεξεργασία συγγραφέων: Δημιουργείται ο intermediate πίνακας article-author (αποσύνθεση pipe-separated λίστας) και αμέσως μετά ο AUTHOR_LOOKUP. Ο AUTHOR_LOOKUP δημιουργείται εδώ γιατί τα επόμενα intermediate tables χρησιμοποιούν author_id αντί για ονόματα.

Στάδιο 3 — Intermediate tables: Καθαρισμός και κανονικοποίηση δεδομένων πριν το fuzzy matching. Αφαίρεση εισαγωγικών από τίτλους (REPLACE(field, ' ', '')).



Intermediated and Author Tables

Στάδιο 4 — Fuzzy Matching: Αντιστοίχιση άρθρων με εγγραφές κατάταξης.

Στάδιο 5.1 — Final lookup & fact tables: Δημιουργία με σειρά: FOR_LOOKUP, BEST_SUBJECT_AREA_LOOKUP, ARTICLES, CONF_RANKING, MAG_RANKING.

Στάδιο 5.2 — Junction tables: Τελευταίοι: CONF_ARTICLE_INFO, MAG_ARTICLE_INFO, ARTICLE_AUTHORS.

Προβλήματα φόρτωσης και αντιμετώπιση

Column bleeding: Και τα τέσσερα αρχεία περιείχαν τον delimiter εντός quoted strings. Η MariaDB διαχώριζε ακόμα και εντός εισαγωγικών. Διορθώθηκε με OPTIONALLY ENCLOSED BY ''.

Μοναδικότητα article_id Τα αρχεία εισόδου input_inproceedings.csv (άρθρα συνεδρίων) και input_article.csv (άρθρα περιοδικών) προέρχονται από εξαγωγή δεδομένων του DBLP, στην οποία κάθε εγγραφή έχει έναν globally unique ακέραιο αναγνωριστικό που δεν επαναλαμβάνεται μεταξύ των δύο αρχείων. Ο πίνακας ARTICLES δημιουργείται με UNION των article_id από τα ενδιάμεσα στάδια συνεδρίων και περιοδικών. Αν δύο άρθρα από διαφορετικές πηγές είχαν ίδιο article_id και ίδιο τίτλο, το UNION θα τα ένωνε σε μία γραμμή, αλλά και οι δύο πίνακες CONF_ARTICLE_INFO και MAG_ARTICLE_INFO θα αναφέρονταν στο ίδιο article_id, οπότε το cross-table test θα απέτυχε. Αν είχαν ίδιο article_id αλλά διαφορετικό τίτλο, το UNION θα κρατούσε και τις δύο γραμμές, προκαλώντας παραβίαση του PRIMARY KEY στον ARTICLES και κατάρρευση του pipeline. Και στις δύο περιπτώσεις η επικάλυψη εντοπίζεται, είτε αυτόματα μέσω

σφάλματος είτε μέσω του `test_cross_table` στο `test_tables.py`, το οποίο ελέγχει ρητά ότι κανένα `article_id` δεν εμφανίζεται ταυτόχρονα στον `CONF_ARTICLE_INFO` και στον `MAG_ARTICLE_INFO`.

Καθαρισμός τίτλων: Οι τίτλοι συνεδρίων, περιοδικών και άρθρων περιείχαν `literal` εισαγωγικά ως αποτέλεσμα της φόρτωσης. Αφαιρέθηκαν με `REPLACE` κατά τη δημιουργία των `intermediate` πινάκων.

Διαχωρισμός συγγραφέων: Το πεδίο `author` στα DBLP αρχεία περιέχει πολλούς συγγραφείς ενωμένους με `|`. Κατά τη δημιουργία του `intermediate article-author` πίνακα, κάθε όνομα διαχωρίστηκε και αποθηκεύτηκε ως ξεχωριστή γραμμή. Για κάθε άρθρο αποκλείστηκαν τυχόν `duplicate` ονόματα. Άρθρα χωρίς συγγραφέα έλαβαν την τιμή `no_author`.

Μέγεθος `ARTICLE_AUTHORS`: Η συνάρτηση `create_final_article_authors` χρησιμοποιεί δύο ξεχωριστές συνδέσεις και `cursors`. Ο `cursor` (η κύρια σύνδεση) διαβάζει τις 7 εκατομμύρια εγγραφές του `intermediate_article_author` σε `chunks` των 100.000 ώστε να μην φορτωθούν όλες στη μνήμη ταυτόχρονα. Ο `write_cursor` (δεύτερη σύνδεση) εκτελεί τα `INSERT` στον `ARTICLE_AUTHORS`. Η αρχιτεκτονική αυτή είναι απαραίτητη για δύο λόγους: πρώτον, η χρήση της ίδιας σύνδεσης για ανάγνωση και εγγραφή ταυτόχρονα προκαλεί σφάλμα "Commands out of sync" στο `mysql-connector-python`, και δεύτερον, η φόρτωση όλων των εγγραφών στη μνήμη πριν τα `INSERT` θα έκανε το βήμα αυτό πολύ αργό.

Κανονικοποίηση ονομάτων συγγραφέων: Το `collation utf8mb4_unicode_ci` είναι `case-insensitive` αλλά όχι `accent-insensitive`. Για να αντιμετωπιστεί η `accent-insensitivity` χρησιμοποιείται `Python-level` κανονικοποίηση. Γίνεται με τη συνάρτηση `_normalize_name` στο `full_pipeline.py`, η οποία εφαρμόζει `NFKD Unicode` κανονικοποίηση και αφαιρεί τους χαρακτήρες κατηγορίας `Mn` (`combining diacritical marks`), δηλαδή τα τονικά σημεία που επισυνάπτονται σε γράμματα. Στη συνέχεια εφαρμόζει `.title()` ώστε κάθε λέξη να ξεκινά με κεφαλαίο γράμμα. Με αυτή τη διαδικασία, ονόματα που διαφέρουν μόνο σε τόνους συγχωνεύονται σε μία εγγραφή. Χαρακτήρες που δεν έχουν `ASCII` αντίστοιχο διατηρούνται αναλλοίωτοι. Η κανονικοποίηση εφαρμόζεται στη συνάρτηση `_format_names_article_ids` πριν την εισαγωγή στον ενδιαμέσο πίνακα `intermediate_article_author`.

Session timeouts για μεγάλα datasets: Κατά τη δημιουργία του πίνακα `ARTICLE_AUTHORS` που περιέχει 7 εκατομμύρια εγγραφές, η σύνδεση με τη βάση δεδομένων ενδέχεται να διακοπεί λόγω των προεπιλεγμένων ορίων αναμονής. Για να αποφευχθεί αυτό, στην αρχή του `pipeline` ορίζονται οι παρακάτω `session` μεταβλητές:

```
SET SESSION wait_timeout = 3600;
SET SESSION interactive_timeout = 3600;
SET SESSION net_read_timeout = 3600;
SET SESSION net_write_timeout = 3600;
```

Τύποι δεδομένων: Τα DBLP αρχεία και το `iCore` ορίζουν ήδη τους σωστούς τύπους, οπότε δεν χρειάζεται μετατροπή. Για το `MAG_RANKING`, οι αριθ-

μητικές στήλες ορίζονται ως INT και DECIMAL απευθείας στο starting, καθώς το source αρχείο δεν περιέχει μη-αριθμητικές τιμές σε αυτές. Εξαίρεση αποτελεί το best quartile: τιμές εκτός Q1-Q4 αποθηκεύονται ως NULL κατά τη μεταφορά στον final πίνακα.

Φιλτράρισμα γραμμών: Και για τα συνέδρια και για τα περιοδικά αποκλείονται γραμμές χωρίς id. Για τα συνέδρια φιλτράρεται WHERE id IS NOT NULL, για τα περιοδικά WHERE mag_rank IS NOT NULL

Quoted names στο bestSubjectArea.csv: Ονόματα κατηγοριών με κόμματα διατηρούσαν τα εισαγωγικά με απλή ανάγνωση. Αντιμετωπίστηκε με csv.reader σε Python.

Fuzzy Matching

Τα ονόματα των venues στο DBLP dataset δεν ταιριάζουν ακριβώς με τα αντίστοιχα στα αρχεία κατάταξης λόγω διαφορών σε συντομεύσεις, σειρά λέξεων και ορθογραφία, οπότε equality join δεν ήταν εφικτό. Υλοποιείσαμε fuzzy matching ξεχωριστά για περιοδικά και συνέδρια, με διαφορετικές παραμέτρους για κάθε περίπτωση. Και στις δύο περιπτώσεις η αντιστοίχιση γίνεται σε επίπεδο μοναδικών venue τίτλων και όχι σε επίπεδο άρθρων, για αποδοτικότητα. Μόλις βρεθεί η αντιστοίχιση για κάθε μοναδικό τίτλο, τα αποτελέσματα συνδέονται πίσω με τα άρθρα.

Κανονικοποίηση

- default_process (rapidfuzz): πεζά, αφαίρεση μη-αλφαριθμητικών.
- Αφαίρεση stopwords (*and, the, on, for, in, of, with*).
- Περιοδικά: αφαίρεση *journal, j*· καταλήξεις (*s, ed, ing, ion*)· εκτενές λεξικό αντικατάστασης (π.χ. *international→i, transactions→t, computer→comp*).
- Συνέδρια: αφαίρεση *conference, symposium, workshop* (σκόπιμη — το iCORE αναφέρει venues χωρίς τον τύπο εκδήλωσης), αριθμοί στο τέλος τίτλου, λατινικοί αριθμοί (*i, ii, iii*), *international→i*.

Σύγκριση

- **Περιοδικά:** fuzz.token_sort_ratio, κατώφλι 88.1 % (ανθεκτικό στη σειρά λέξεων).
- **Συνέδρια:** fuzz.WRatio, κατώφλι 92.2 % (σταθμισμένος συνδυασμός μετρικών, ανθεκτικό σε σύντομα strings).

* Δεύτερο πέρασμα για συνέδρια: αν ο κανονικοποιημένος τίτλος ενός άρθρου ταιριάζει ακριβώς με το κανονικοποιημένο acronym κάποιου συνεδρίου (score 100), και αυτό το score είναι καλύτερο από το αποτέλεσμα του fuzzy title matching, χρησιμοποιείται η acronym αντιστοίχιση.

Blacklist / Whitelist Γνωστά false positives (venues που έχουν παρόμοιο όνομα) αποκλείονται μέσω blacklist, εκτός αν το score είναι 100, δηλαδή ακριβής ταύτιση. Αντίστοιχα, αντιστοιχίσεις που δεν βρίσκονται αυτόματα λόγω μεγάλων διαφορών στον τίτλο ορίζονται χειροκίνητα μέσω whitelist.

Unmatched venues Venues που δεν βρέθηκε αντιστοίχιση δεν αποκλείονται καθώς δεν θέλουμε να χαθούν τα άρθρα τους. Κάθε unmatched venue λαμβάνει νέο συνθετικό ID (πάνω από το μέγιστο υπάρχον ID των ranking entries) και εισάγεται στη ranking dataframe με is_ranked = False και τίτλο τον αρχικό τίτλο του DBLP, ώστε κάθε άρθρο έχει πάντα έγκυρο venue ID και εισάγεται κανονικά στον CONF_ARTICLE_INFO ή MAG_ARTICLE_INFO. Στον τελικό πίνακα CONF_RANKING αυτά τα venues λαμβάνουν conf_rank = 'unranked', και στον mag_rank = NULL. Τα άρθρα τους παραμένουν προσβάσιμα από όλα τα ερωτήματα, απλά χωρίς κατάταξη.

Τα score thresholds, οι scorers, τα λεξικά αντικατάστασης, τα σύνολα λέξεων που αφαιρούνται, καθώς και οι blacklist και whitelist, δεν προέκυψαν από θεωρητική ανάλυση αλλά εμπειρικά μέσω επαναληπτικής δοκιμής και ελέγχου των αποτελεσμάτων. Υψηλότερα thresholds μειώνουν false positives αλλά αυξάνουν τα unmatched άρθρα. Σε κάθε iteration εξετάζαμε τα matched ζεύγη και προσαρμόζαμε τις παραμέτρους ώστε να μειωθούν τα false positives. Δεν υπάρχει εγγύηση ότι δεν υπάρχουν venues που θα έπρεπε να έχουν ταιριάξει αλλά κατέληξαν ως unmatched Αντίθετα, τα matched ζεύγη ελέγχθηκαν χειροκίνητα και επιβεβαιώθηκε ότι δεν περιέχουν false positives.

Repeatability

original_files: Εκτελεί ολόκληρο το ETL από τα αρχικά αρχεία. Αν create_backup = true, δημιουργείται αυτόματα compressed backup.

backup: Αποκαθιστά από bibinatorDB.sql.gz Το backup δημιουργείται με mysqldump + gzip.

Backup

- Δημιουργείται με mysqldump και αποθηκεύεται συμπιεσμένο με gzip στο data/backup/bibinatorDB.sql.gz.
- Περιέχει αποκλειστικά τους εννέα τελικούς πίνακες, ανεξάρτητα από το αν οι staging και intermediate πίνακες εξακολουθούν να υπάρχουν στη βάση. Η λίστα των πινάκων ορίζεται στατικά στον κώδικα και φιλτράρεται μέσω INFORMATION_SCHEMA.TABLES ώστε να συμπεριληφθούν μόνο αυτοί. Η σειρά dump τηρεί την εξάρτηση foreign keys μέσω FIELD().
- Πριν από το dump προστίθεται στο αρχείο backup χειροκίνητα header που περιέχει DROP DATABASE IF EXISTS, CREATE DATABASE IF NOT EXISTS bibinatorDB CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci, και USE. Κανονικά αυτό το αναλαμβάνει η παράμετρος --databases του mysqldump, αλλά στη MariaDB ο συνδυασμός --databases με --tables (που χρειαζόμαστε για να ορίσουμε τη σειρά) δεν συμπεριλαμβάνει το USE statement

στην έξοδο. Για αυτό χρησιμοποιούμε μόνο `--tables` και προσθέτουμε το `header` χειροκίνητα. Έτσι το `backup` είναι αυτόνομο: αποκαθιστά τη βάση από μηδέν χωρίς να χρειάζεται να υπάρχει ήδη η βάση στον `server`.

Σημειώνουμε ότι το `backup.py` εκτελεί `mysqldump` για τη δημιουργία αντιγράφου ασφαλείας. Ο MySQL 8.0 client του `mysqldump` απαιτεί τη σημαία `--column-statistics=0` όταν συνδέεται σε MariaDB, ενώ ο MariaDB client δεν αποδέχεται αυτή τη σημαία. Για να αντιμετωπιστεί αυτό, το `backup.py` ελέγχει αυτόματα την έκδοση του `mysqldump` που είναι εγκατεστημένη με τη συνάρτηση `_is_mysql_client()`: εκτελεί `mysqldump --version` και ελέγχει αν η έξοδος περιέχει τη λέξη "MariaDB". Αν δεν την περιέχει, εφαρμόζεται η σημαία `--column-statistics=0`.

Testing

Για επαλήθευση εγγυρώτητας τόσο της βάσης όσο και των `sql queries` που χρησιμοποιούνται στο πλαίσιο της εφαρμογής, έχουμε δημιουργήσει tests.

- Το αρχείο `src/setup/test_tables.py` περιέχει αυτοματοποιημένα tests για την ακεραιότητα των πινάκων της βάσης δεδομένων. Κατά την εκτέλεση, συνδέεται απευθείας στην κύρια βάση δεδομένων μέσω των ρυθμίσεων του `DB_CONFIG` και εκτελεί έναν έλεγχο για κάθε έναν από τους εννέα πίνακες καθώς και έναν διαπινακικό έλεγχο. Για κάθε πίνακα επαληθεύεται η ύπαρξή του, ο αναμενόμενος αριθμός γραμμών, η απουσία τιμών `NULL` ή κενών σε κρίσιμα πεδία, η εγκυρότητα των αριθμητικών τιμών, καθώς και η παρουσία τιμών-placeholder όπου απαιτείται.
- Το αρχείο `src/app/test_queries.py` περιέχει αυτοματοποιημένα tests για τα ερωτήματα της εφαρμογής. Κατά την εκτέλεση, δημιουργείται μια προσωρινή βάση δεδομένων `bibinatorTestDB` στην οποία φορτώνεται το αρχείο `data/test_fixture.sql` με δεδομένα-placeholders. Στη συνέχεια εκτελείται κάθε ερώτημα και επαληθεύονται τα αποτελέσματα με βάση τα γνωστά δεδομένα του `fixture`. Στο τέλος, η προσωρινή βάση διαγράφεται.

Και στα δύο αρχεία tests χρησιμοποιείται η εξαίρεση `_TestFailure`. Όταν μια επαλήθευση αποτύχει, εκτυπώνεται μήνυμα αποτυχίας και γίνεται `raise` η εξαίρεση `_TestFailure`, η οποία σταματά την εκτέλεση του τρέχοντος test. Ο runner κάθε αρχείου πιάνει αυτή την εξαίρεση, καταγράφει το όνομα του test που απέτυχε και συνεχίζει με το επόμενο test. Έτσι εκτελούνται όλα τα tests ανεξάρτητα από τις επιμέρους αποτυχίες, και στο τέλος εκτυπώνεται συνολική αναφορά με τα tests που απέτυχαν.

2.2 Διαγράμματα Πακέτων / Υποσυστημάτων Κεντρικής Εφαρμογής

Package diagram εφαρμογής

config.ini

└─ read by both _config.py files

src/setup/ package

main.py

└─ _config.py (reads config.ini → DB_CONFIG, DB_NAME, MODE, flags)

└─ [MODE=original_files] → full_pipeline.py

└─ └─ _config.py

└─ └─ fuzzy_matching.py (rapidfuzz, pandas, mysql.connector)

└─ └─ test_tables.py (mysql.connector)

└─ └─ export_tables.py (csv, mysql.connector)

└─ └─ backup.py (gzip, subprocess → mysqldump)

└─ [MODE=backup] → backup_pipeline.py

└─ └─ _config.py

└─ └─ test_tables.py

└─ └─ export_tables.py

└─ └─ backup.py (gzip, subprocess → mysqldump)

└─ [MODE=validate] → test_tables.py (mysql.connector)

src/app/ package

main.py

└─ _config.py (reads config.ini → DB_CONFIG, DB_NAME, APP_MODE, APP_PORT)

└─ [APP_MODE=run] → app.py (streamlit, plotly, pandas, mysql.connector)

└─ └─ queries.py (plain SQL constants, no imports)

└─ └─ theme.py (plotly.graph_objects → COLORS, PLOTLY_TEMPLATE)

└─ [APP_MODE=test_queries] → test_queries.py (mysql.connector)

Το σύστημα αποτελείται από δύο ανεξάρτητα υποσυστήματα:

1. **ETL Subsystem** (src/setup/): Εκτελείται εφάπαξ για τη φόρτωση της βάσης. Εκκινείται είτε με την χρήση των setup.bat, setup.sh ανάλογα το λειτουργικό σύστημα, είτε απευθείας με python main.py.
2. **Query Application** (src/app/): Streamlit web app. Συνδέεται στη MySQL μέσω mysql.connector. Εκκινείται είτε με την χρήση των bibinator.bat, bibinator.sh ανάλογα το λειτουργικό σύστημα, είτε απευθείας με streamlit run app.py.

2.3 Διαγράμματα Κλάσεων Κεντρικής Εφαρμογής

Η εφαρμογή ακολουθεί **διαδικαστική αρχιτεκτονική**. Το app.py ορίζει όλη τη λογική UI σε συναρτήσεις. Το queries.py περιέχει τα SQL strings ως named constants.

Συνάρτηση	Σελίδα	Περιγραφή
get_connection()	—	@st.cache_resource: MySQL σύνδεση
run_query()	—	Εκτελεί ερώτημα, επιστρέφει DataFrame
fetch_quick_stats()	—	@st.cache_data(ttl=3600): global stats
section_venue_profile()	Venue Profile	Αναζήτηση συνεδρίου/περιοδικού
section_author_profile()	Author Profile	Αναζήτηση συγγραφέα
section_year_profile()	Year Profile	Στατιστικά ανά έτος
section_linecharts()	Line Charts	Τάσεις ανά venue / κατηγορία
section_barcharts()	Bar Charts	Σύγκριση venues / publishers
section_scatterplots()	Scatter Plots	Journal metrics / authors vs papers

3 Υποδείγματα Ερωτήσεων και Απαντήσεων

Παρακάτω παρουσιάζονται τα κύρια SQL ερωτήματα ανά σελίδα της εφαρμογής.

3.1 Homepage

Στην αρχική σελίδα της εφαρμογής εμφανίζονται μερικές κάρτες με γενικότερα στατιστικά στοιχεία για τα δεδομένα της βάσης. Σημειώνεται ότι, με σκοπό τα στατιστικά αυτά να υπολογίζονται όσο το δυνατό πιο γρήγορα, επιλέξαμε τον υπολογισμό τους με βάση `information_schema.TABLES` οπότε μπορεί να παρουσιάζουν μικρές ανακρίβειες.

```


SELECT
  (SELECT table_rows FROM information_schema.TABLES
   WHERE table_schema = DATABASE() AND table_name = 'CONF_RANKING') AS
    n_conf,
  (SELECT table_rows FROM information_schema.TABLES
   WHERE table_schema = DATABASE() AND table_name = 'MAG_RANKING') AS
    n_mag,
  (SELECT table_rows FROM information_schema.TABLES
   WHERE table_schema = DATABASE() AND table_name = 'ARTICLES') AS
    n_papers,
  (SELECT table_rows FROM information_schema.TABLES
   WHERE table_schema = DATABASE() AND table_name = 'AUTHOR_LOOKUP') AS
    n_authors,
  (SELECT MIN(y) FROM (
    SELECT year AS y FROM CONF_ARTICLE_INFO
    UNION SELECT year FROM MAG_ARTICLE_INFO
  ) u) AS min_yr,
  (SELECT MAX(y) FROM (
    SELECT year AS y FROM CONF_ARTICLE_INFO

```

```
UNION SELECT year FROM MAG_ARTICLE_INFO
) u) AS max_yr
```

QUICK_STATS

Για λόγους απόδοσης, τα στατιστικά πλήθους (n_{conf} , n_{mag} , n_{papers} , n_{authors}) δεν υπολογίζονται με `COUNT(*)` αλλά διαβάζονται από το `information_schema.TABLES.table_rows`, το οποίο περιέχει εκτίμηση που διατηρεί η μηχανή αποθήκευσης. Για πίνακες InnoDB η τιμή αυτή είναι προσεγγιστική και μπορεί να αποκλίνει από τον πραγματικό αριθμό εγγγραφών. Καθώς οι πίνακές μας δεν ανανεώνονται συχνά, η απόκλιση αυτή είναι αμελητέα. Το εύρος ετών (`min_yr`, `max_yr`) υπολογίζεται με ακριβή `MIN/MAX` ερωτήματα και είναι πάντα ακριβές.



Homepage Quick Stats

3.2 Venue Profile

Ο χρήστης πληκτρολογεί τίτλο ή ακρωνύμιο (slider έτους 1936–2014) και λαμβάνει: κατάταξη, 5 summary stats, line chart τάσεων, πίνακα άρθρων.

```
SELECT cai.year AS year,
       COUNT(DISTINCT cai.article_id) AS num_papers,
       COUNT(aa.author_id) AS total_authors,
       COUNT(DISTINCT aa.author_id) AS distinct_authors
FROM CONF_ARTICLE_INFO cai
JOIN CONF_RANKING cr ON cr.conf_id = cai.conf_id
JOIN ARTICLE_AUTHORS aa ON aa.article_id = cai.article_id
WHERE (cr.title LIKE %s OR cr.acronym LIKE %s) AND cai.year BETWEEN %s AND %s
GROUP BY cai.year ORDER BY cai.year
```

VENUE_STATS_CONF – τάσεις ανά έτος

```

SELECT ar.article_id AS id, ar.title,
       GROUP_CONCAT(DISTINCT au.author_name SEPARATOR ', ') AS authors,
       cai.year
FROM ARTICLES ar
JOIN CONF_ARTICLE_INFO cai ON cai.article_id = ar.article_id
JOIN CONF_RANKING cr      ON cr.conf_id      = cai.conf_id
JOIN ARTICLE_AUTHORS aa   ON aa.article_id   = ar.article_id
JOIN AUTHOR_LOOKUP au     ON au.author_id    = aa.author_id
WHERE (cr.title LIKE %s OR cr.acronym LIKE %s)
      AND cai.year BETWEEN %s AND %s
GROUP BY ar.article_id, ar.title, cai.year
ORDER BY cai.year DESC

```

VENUE_PAPERS_CONF – λίστα άρθρων



Venue Profile

3.3 Author Profile

Ο χρήστης πληκτρολογεί όνομα συγγραφέα και λαμβάνει: πρώτο/τελευταίο έτος, σύνολο άρθρων, μέσο όρο/έτος, line chart ανά έτος (συνέδρια / περιοδικά).

```

SELECT year,
       SUM(conf_papers) AS conf_papers,
       SUM(journal_papers) AS journal_papers
FROM (
  SELECT cai.year AS year,
         COUNT(DISTINCT cai.article_id) AS conf_papers, 0 AS
         journal_papers
  FROM ARTICLE_AUTHORS aa
  JOIN AUTHOR_LOOKUP au ON au.author_id = aa.author_id


```

```

JOIN CONF_ARTICLE_INFO cai ON cai.article_id = aa.article_id
WHERE au.author_name = %s
GROUP BY cai.year
UNION ALL
SELECT mai.year AS year, 0 AS conf_papers,
       COUNT(DISTINCT mai.article_id) AS journal_papers
FROM ARTICLE_AUTHORS aa
JOIN AUTHOR_LOOKUP au ON au.author_id = aa.author_id
JOIN MAG_ARTICLE_INFO mai ON mai.article_id = aa.article_id
WHERE au.author_name = %s
GROUP BY mai.year
) sub
GROUP BY year ORDER BY year

```

AUTHOR_ACTIVITY



Author Profile

3.4 Year Profile

Ο χρήστης επιλέγει έτος (1936–2014) και λαμβάνει 5 global stats και φιλτραρισμένο πίνακα δημοσιεύσεων.

```

WITH conf AS (
  SELECT COUNT(DISTINCT cai.article_id) AS n_papers,
         COUNT(DISTINCT cai.conf_id) AS n_venues,
         COUNT(aa.author_id) AS n_authors
  FROM CONF_ARTICLE_INFO cai
  JOIN ARTICLE_AUTHORS aa ON aa.article_id = cai.article_id
  WHERE cai.year = %s
), jrn1 AS (
  SELECT COUNT(DISTINCT mai.article_id) AS n_papers,
         COUNT(DISTINCT mai.mag_id) AS n_venues,


```

```

        COUNT(aa.author_id) AS n_authors
FROM MAG_ARTICLE_INFO mai
JOIN ARTICLE_AUTHORS aa ON aa.article_id = mai.article_id
WHERE mai.year = %s
), dist AS (
    SELECT COUNT(DISTINCT author_id) AS n_dist FROM (
        SELECT aa.author_id FROM CONF_ARTICLE_INFO cai
        JOIN ARTICLE_AUTHORS aa ON aa.article_id = cai.article_id
        WHERE cai.year = %s
        UNION
        SELECT aa.author_id FROM MAG_ARTICLE_INFO mai
        JOIN ARTICLE_AUTHORS aa ON aa.article_id = mai.article_id
        WHERE mai.year = %s
    ) u
)
SELECT conf.n_papers + jrnل.n_papers AS num_papers,
       conf.n_venues AS num_conf,
       jrnل.n_venues AS num_journals,
       conf.n_authors + jrnل.n_authors AS num_authors,
       dist.n_dist AS num_distinct_authors
FROM conf, jrnل, dist

```

YEAR_STATS – παράδειγμα για έτος Y



Year Profile

3.5 Line Charts

Tab 1 – Selected Venues: Ο χρήστης εισάγει comma-separated venues και επιλέγει metric.

```

SELECT cai.year AS year,
       COUNT(DISTINCT cai.article_id) AS num_papers,
       COUNT(aa.author_id) AS total_authors,

```

```

COUNT(DISTINCT aa.author_id) AS distinct_authors
FROM CONF_ARTICLE_INFO cai
JOIN CONF_RANKING cr ON cr.conf_id = cai.conf_id
JOIN ARTICLE_AUTHORS aa ON aa.article_id = cai.article_id
WHERE (cr.title LIKE %s OR cr.acronym LIKE %s)
AND cai.year BETWEEN %s AND %s
GROUP BY cai.year
ORDER BY cai.year

```

VENUE_TREND_CONF


Tab 2 – By Category: Αριθμός venues ανά FoR (iCORE) ή Subject Area (Kaggle) ανά έτος.

```

SELECT cai.year, cr.primary_for, COUNT(DISTINCT cai.conf_id) AS num_venues
FROM CONF_ARTICLE_INFO cai
JOIN CONF_RANKING cr ON cr.conf_id = cai.conf_id
WHERE (%s IS NULL OR cr.primary_for = %s)
AND cai.year BETWEEN %s AND %s
GROUP BY cai.year, cr.primary_for
ORDER BY cai.year

```

CATEGORY_TREND_CONF



Line Charts - Multi-Venue Trend



Line Charts - Category Trend

3.6 Bar Charts

Tab 1 – Venues Comparison: Σύγκριση metric για επιλεγμένα venues.


```
SELECT COUNT(DISTINCT cai.article_id)
      AS total_papers,
      COUNT(DISTINCT cai.article_id) / NULLIF(COUNT(DISTINCT cai.year), 0)
      AS avg_papers_per_year,
      COUNT(aa.author_id) / NULLIF(COUNT(DISTINCT cai.year), 0)
      AS avg_authors_per_year
FROM CONF_ARTICLE_INFO cai
JOIN CONF_RANKING cr      ON cr.conf_id = cai.conf_id
LEFT JOIN ARTICLE_AUTHORS aa ON aa.article_id = cai.article_id
WHERE (cr.title LIKE %s OR cr.acronym LIKE %s)
```

VENUE_AGGREGATE_CONF

Tab 2 – Publisher Statistics: Αριθμός περιοδικών ανά publisher, χρωματισμένα ανά quartile.

```
SELECT publisher, best_quartile, COUNT(*) AS num_journals
FROM MAG_RANKING
WHERE publisher IS NOT NULL AND publisher != ''
      AND best_quartile IS NOT NULL AND best_quartile != ''
      AND (%s IS NULL OR publisher LIKE %s)
GROUP BY publisher, best_quartile
ORDER BY publisher, best_quartile
```

PUBLISHER_QUARTILE



Bar Charts - Venue Comparison



Bar Charts - Publisher Quartiles

3.7 Scatter Plots

Tab 1 – Journal Metrics: Κάθε σημείο = ένα περιοδικό. Επιλέξιμοι X/Y άξονες: TotalDocs, TotalDocs3y, TotalCites3y, TotalRefs, CitableDocs3y, CitesPerDoc2y, RefsPerDoc. Προαιρετικός χρωματισμός ανά BestQuartile.

Tab 2 – Avg Authors vs. Papers per Year: Κάθε σημείο = ένα έτος.


```
SELECT cai.year,
       COUNT(aa.author_id) / NULLIF(COUNT(DISTINCT cai.article_id),0) AS
       avg_authors,
       COUNT(DISTINCT cai.article_id) AS num_papers
```

```
FROM CONF_ARTICLE_INFO cai
JOIN ARTICLE_AUTHORS aa ON aa.article_id = cai.article_id
GROUP BY cai.year ORDER BY cai.year
```

SCATTER_TREND_CONF



Scatter Plots - Metrics



Scatter Plots - Authors vs Papers per Year

4 Λοιπά Σχόλια

4.1 Επιλογές Σχεδιασμού και Trade-offs

Views: Καθώς τα ερωτήματα είναι παραμετρικά (οι χρήστες ορίζουν τις θεμιτές τιμές στα φίλτρα) και τα views στην SQL είναι στατικοί ορισμοί, προκειμένου να τα χρησιμοποιήσουμε θα χρειαζόταν και πάλι εφαρμογή παραμέτρων WHERE καθώς δεν θα μπορούσαν να υποκαταστήσουν παραμετρικά ερωτήματα. Η υλοποίηση μας έγινε χωρίς την χρήση τους.

Streamlit connection caching: Η `get_connection()` με `@st.cache_resource` (singleton ανά process). Η `fetch_quick_stats()` με `@st.cache_data(ttl=3600)` για αποφυγή επανεκτέλεσης ακριβών COUNT queries σε κάθε φόρτωση της Home page.

Thread safety: Το `run_query()` χρησιμοποιεί `threading.Lock()` για να αποτρέψει ταυτόχρονη χρήση του connector από πολλαπλά Streamlit threads.

4.2 Επιλογές Setup

Πέρα από τα δύο modes φόρτωσης δεδομένων (`original_files`, `backup`), το `config.ini` παρέχει ένα ακόμη mode καθώς και ορισμένες boolean επιλογές:

mode = validate: Το mode Validate εκτελεί μόνο τα tests επαλήθευσης (`test_tables.py`) στη βάση που υπάρχει ήδη, χωρίς να εκτελέσει ξανά το pipeline.

run_tests: Validation tests μετά τη φόρτωση (αριθμός εγγραφών, NULL counts, FK consistency). Ισχύει και για τα δύο loading modes.

drop_staging_tables: Διαγραφή starting/intermediate tables. Μόνο για `original_files`.

export_final_tables: Εξαγωγή τελικών πινάκων ως CSV σε `data/final_tables/`. Και για τους δύο loading modes.

create_backup: Compressed backup. Μόνο για `original_files`.

4.3 Επιλογές Εφαρμογής Bibinator

Το αρχείο `config.ini` παρέχει δύο modes για την εφαρμογή:

run: Εκκινεί την εφαρμογή Streamlit.

test_queries: Εκτελεί τα tests ερωτημάτων (`test_queries.py`) αντί να ξεκινήσει την εφαρμογή. Χρησιμοποιείται για να επαληθευθεί η ορθότητα των SQL ερωτημάτων σε μια δοκιμαστική βάση δεδομένων.

4.4 Γνωστοί Περιορισμοί

- Οι τίτλοι άρθρων αποκόπτονται στους 255 χαρακτήρες (`VARCHAR(255)`).
- Ερωτήματα σε `ARTICLE_AUTHORS` χωρίς composite index μπορεί να χρειαστούν 5–15 δευτερόλεπτα.

- Αναζήτηση venue με LIKE '%term%' δεν επωφελείται από index — αποδεκτό για τους μικρούς ranking πίνακες.
- Δεν υποστηρίζεται αναζήτηση author με partial name.
- Τα δεδομένα καλύπτουν έτη 1936–2014 (ορίζεται από τα διαθέσιμα DBLP αρχεία).

4.5 Εκτέλεση Εφαρμογής

Για την εκτέλεση της εφαρμογής όπως έχει προαναφερθεί δημιουργήθηκαν scripts .bat και .sh τα οποία:

- επιβεβαιώνουν την ύπαρξη στο σύστημα python και SQL για την λειτουργία της εφαρμογής
- ανοίγουν virtual python environment
- ελέγχουν την ύπαρξη όλων των εξαρτήσεων για την λειτουργία της εφαρμογής και κατεβάζουν οτιδήποτε λείπει
- τρέχουν τον αντίστοιχο κώδικα (setup / app)

```
.\setup.bat or .\setup.sh
.\bibinator.bat or .\bibinator.sh
```

Εγκατάσταση και εκκίνηση

Εξαρτήσεις (Python 3.11+)

Βιβλιοθήκη	Έκδοση	Χρήση
mysql-connector-python	9.7.0	Σύνδεση MySQL
streamlit	1.x	Web UI framework
pandas	3.0.2	DataFrames, CSV I/O
plotly	5.x	Interactive charts
rapidfuzz	3.14.5	Fuzzy string matching
openpyxl	3.1.5	Ανάγνωση .xlsx (icoreCategories)